

Математическая статистика. Теория

Александр Сергеев

1 Введение

Есть генеральная совокупность. Надо выбрать часть генеральной совокупности – выборку. По выборке хотим сделать вывод о всей совокупности

В исследовании есть следующие этапы

1. Сбор данных
2. Препроцессинг (чистка)
3. Построение модели и анализ
4. Интерпретация

Определение

Репрезентативность – свойство выборки, означающее, что по выборке можно судить по всей совокупности

2 Простейшая модель выборки. Эмпирическая функция распределения

Простейшая модель выборки

X_1, \dots, X_n – i.i.d.

F – функция распределения (теоретическая, мы ее не знаем)

x_1, \dots, x_n – реализация выборки

Глобальная цель – оценить из реализации x_1, \dots, x_n теоретическую функцию F

Определение (эмпирическая функция выборки)

$$\mu_n(t) = \sum_{i=1}^n \mathbb{1}(X_i \leq t)$$

$$F_n(t) = \frac{\mu_n(t)}{n} - \text{эмпирическая функция распределения}$$

Замечание

Заметим, что $\mathbb{1}(X_i \leq t) \sim \text{Bin}(F(t))$

Тогда $\mu_n(t) \sim \text{Bin}(n, F(t))$

$$P(F_n(x) = \frac{k}{n}) = P(\mu_n(x) = k) = \binom{n}{k} F_n^k(x) (1 - F_n(x))^{n-k}$$

Отсюда $E(\mu_n(x)) = nF_n(x)$

$E(F_n(t)) = F(t)$ – несмещенность

$$\text{Var } F_n(t) = \frac{F(t)(1 - F(t))}{n}$$

По ЦПТ $\frac{\mu_n(t) - nF(t)}{\sqrt{F(t)(1 - F(t))n}} = \sqrt{n} \frac{F_n(t) - F(t)}{\sqrt{F(t)(1 - F(t))}} \xrightarrow{d} N(0, 1)$ – асимптотическая нормальность

Теорема Гливенко – Кантелли

$$\sup_{t \in \mathbb{R}} |F_n(t) - F(t)| \xrightarrow[n \rightarrow \infty]{a.s.} 0$$

Теорема Колмагорова

$$D_n = \sup_x |F_n(x) - F(x)|, F \in C(\mathbb{R}), t \geq 0 \Rightarrow P(\sqrt{n}D_n \leq t) \rightarrow K(t) =$$

$$\sum_{j=-\infty}^{\infty} e^{-2j^2 t^2} - \text{функция распределения Колмагорова}$$

Теорема Смирнова

$X_1, \dots, X_n, Y_1, \dots, Y_n$ – независимы

Обе распределены на $F \in C(\mathbb{R})$

$$D_{m,n} = \sum_x |F_n(x) - F_m(x)|$$

$$\text{Тогда } P(\sqrt{\frac{nm}{n+m}} D_{m,n} \leq t) \xrightarrow{m,n \rightarrow \infty} K(t)$$

3 Выборочные моменты

$\alpha_k = EX_1^k$ – k -ый теоретический момент

$\beta_k = E(X_1 - EX_1)^k$ – k -ый теоретический момент

$$\overline{g(X)} := \frac{1}{n} \sum_{k=1}^n g(X_k), g(\bullet) : \mathbb{R} \rightarrow \mathbb{R}$$

$$\hat{\alpha}_k = \overline{X^k} = \frac{1}{n} \sum_{j=1}^n X_j^k \text{ – } k\text{-ый выборочный момент}$$

$E\hat{\alpha}_k = \alpha_k$ – несмещенность

$$\text{Var } \hat{\alpha}_k = \frac{1}{n} \text{Var}(X_1^k) = \frac{1}{n} ((EX_1^{2k}) - (EX_1^k)^2)$$

$$\text{По ЦПТ } \sqrt{n} \frac{\hat{\alpha}_k - \alpha_k}{\sqrt{\alpha_{2k} - \alpha_k^2}} \approx N(0, 1)$$

$$\sqrt{n} \frac{\hat{\alpha}_k - \alpha_k}{\sqrt{\hat{\alpha}_{2k} - \hat{\alpha}_k^2}} = \sqrt{n} \frac{\hat{\alpha}_k - \alpha_k}{\sqrt{\alpha_{2k} - \alpha_k^2}} \underbrace{\sqrt{\frac{\alpha_{2k} - \alpha_k^2}{\hat{\alpha}_{2k} - \hat{\alpha}_k^2}}}_{\rightarrow 1} \approx N(0, 1)$$

Пояснение

$$\hat{\alpha}_k \xrightarrow{P} \alpha_k \text{ (ЗБЧ)}$$

$$\hat{\beta}_k = \overline{(X - \overline{X})^k} = \frac{1}{n} \sum_{j=1}^n (X_j - \overline{X})^k \text{ – } k\text{-ый центральный выборочный мо-}$$

мент

$$\hat{\beta}_2 = S_*^2 \text{ – выборочная дисперсия}$$

S_* – выборочное отклонение

Замечание

Выборочные моменты – моменты, посчитанные относительно эмпирического распределения

Тогда для них действуют утверждения, свойственные обычным моментам

$$S_*^2 = \overline{X^2} - (\overline{X})^2$$

$$\hat{\beta}_k = \text{Poly}(\hat{\alpha}_k, \dots, \hat{\alpha}_1)$$

$$\text{Т.к. } \hat{\alpha}_k \xrightarrow{P} \alpha_k, \text{ то } \hat{\beta}_k \xrightarrow{P} \beta_k$$

Отступление

Пусть ξ_n – последовательность случайных векторов и $\sqrt{n}(\xi_n - \mu) \xrightarrow{d} N(0, \Sigma)$

μ – какой-то вектор (необязательно матожидание)

$$1. \xi_n \xrightarrow{P} \mu$$

$$\text{Т.к. } (\xi_n - \mu) \frac{\sqrt{n}}{\sqrt{n}} \xrightarrow{d} 0$$

$$2. \text{ Пусть } \phi : \mathbb{R}^m \rightarrow \mathbb{R}, \phi \in C^1(\mathbb{R})$$

$$\phi(\xi_n) \approx \phi(\mu) + \nabla \phi(\mu)(\xi_n - \mu)$$

$$\phi(\xi_n) - \phi(\mu) \approx \nabla \phi(\mu)(\xi_n - \mu)$$

$$\text{Var}(\phi(\xi_n) - \phi(\mu)) \approx \text{Var}(\nabla \phi(\mu)(\xi_n - \mu)) = \nabla \phi(\mu) \text{Var}(\xi_n) (\nabla \phi(\mu))^T$$

$$\text{Тогда } \sqrt{n}(\phi(\xi_n) - \phi(\mu)) \approx \sqrt{n} \nabla \phi(\mu)(\xi_n - \mu) \rightarrow N(0, \nabla \phi(\mu) \Sigma (\nabla \phi(\mu))^T)$$

Теорема

Пусть $\xi_n = (\bar{X}, \dots, \bar{X}^k)$

(Многомерная ЦПТ $\Rightarrow \sqrt{n}(\xi_n - \alpha) \xrightarrow{d} N(0, \sigma), \alpha = (\alpha_1, \dots, \alpha_k), \Sigma = \text{Var}(X_1, \dots, X_1^k)$)

$$\phi : \mathbb{R}^k \rightarrow \mathbb{R}, \phi \in C^1(\mathbb{R})$$

$$\sigma^2 = \nabla \phi(\alpha) \Sigma (\nabla \phi(\alpha))^T > 0$$

$$\text{Тогда } \sqrt{n} \frac{\phi(\xi_n) - \phi(\alpha)}{\sigma} \xrightarrow{d} N(0, 1)$$

$$\text{Кроме того, } \sigma = \sigma(\alpha) \in C^1(\mathbb{R}) \Rightarrow \sqrt{n} \frac{\phi(\xi_n) - \phi(\alpha)}{\sigma(\xi_n)} \xrightarrow{d} N(0, 1)$$

Упражнение

$$\sqrt{n} \frac{S_*^2 - \sigma^2}{\sqrt{\hat{\beta}_4 - S_*^4}} \approx N(0, 1)$$

$$ES_*^2 = \frac{n-1}{n} \sigma^2$$

$$S^2 := \frac{n}{n-1} S_*^2 = \frac{1}{n-1} \sum_{i=1}^n (X - \bar{X})^2 - \text{исправленная (несмещенная) дисперсия}$$

Коэффициент асимметрии

$$\frac{E(X - EX)^3}{\sigma^3}$$

$$\text{Тогда } \frac{\hat{\beta}_3}{S_*^3} - \text{выборочный коэффициент асимметрии}$$

Коэффициент эксцесса

$$\frac{E(X - EX)^4}{\sigma^4} - 3 \mapsto \frac{\hat{\beta}_4}{\sigma_*^4} - 3$$

Ковариация

$$\text{Cov}(X, Y) = EXY - EXEY \mapsto S_{*XY} = \frac{1}{n} \sum_j (X_j - \bar{X})(Y_j - \bar{Y}) = \frac{1}{n} \sum_j X_j Y_j - \bar{X}\bar{Y}$$

Корреляция

$$\rho = \frac{\text{Cov}(X, Y)}{\sqrt{\text{Var } X \text{Var } Y}} \mapsto \rho_n = \frac{S_{*XY}}{S_{*X} S_{*Y}}$$

4 Порядковые статистики

Определение

Вариационный ряд – выборка $X_{(1)} \leq \dots \leq X_{(m)}$

Определение

$X_{(k)}$ – k -ая порядковая статистика

Напоминание

Квантиль порядка α – $q_\alpha : P(X \geq q_\alpha) \geq 1 - \alpha, P(X \leq q_\alpha) \geq \alpha$

Если F – строго монотонная, то $F(q_\alpha) = \alpha \Leftrightarrow q_\alpha = F^{-1}(\alpha)$

Определение

Выборочный квантиль порядка 0 = $\min X_i$

Выборочный квантиль порядка 1 = $\max X_i$

Выборочный квантиль порядка $\alpha \in (0, 1)$:

$$\exists 0 \leq k \leq n - 1 : \frac{k}{n} \leq \alpha < \frac{k+1}{n}$$

Тогда $X_{(k)}$ – искомый квантиль

$$\alpha = \frac{1}{4} - \text{первый (нижний) квартиль}$$

$$\alpha = \frac{1}{2} - \text{второй квартиль, выборочная медиана}$$

$$\alpha = \frac{3}{4} - \text{третий (верхний) квартиль}$$

$$\alpha = 1 - \text{четвертый квартиль / максимум}$$

$$n = 2m \Rightarrow \text{med}(X) = \frac{X_{(m)} + X_{(m+1)}}{2}$$

$$n = 2m + 1 \Rightarrow \text{med}(X) = X_{(m+1)}$$

$$P(X_{(k)} \leq t) = P(\mu_n(t) \geq k) = B(F(t), k, n - k + 1)$$

Пусть $p(t)$ – теоретическая плотность т.е. $p = F'$

$$P(X_{(k)} \leq t)'_t = \frac{\Gamma(n+1)}{\Gamma(k)\Gamma(n-k+1)} F^{k-1}(t)(1-F(t))^{n-k} p(t) - \text{плотность } k\text{-ой}$$

порядковой статистики

$$g(x_1, x_2) = \frac{n!}{(k-1)!(r-k-1)!(n-r)!} F^{k-1}(x_1)(F(x_2) - F(x_1))^{r-k-1}(1 - F(x_2))^{n-r} p(x_1)p(x_2) - \text{совместная плотность вектора } (x_{(k)}, x_{(r)}), k < r$$

$$g(x_1, \dots, x_n) = n!p(x_1) \dots p(x_n) - \text{плотность для вектора всех статистик } (X_{(1)}, \dots, X_{(n)})$$

Определение

Средний член вариационного ряда $-X_{(k(n))}, \frac{k(n)}{n} \rightarrow \text{const} \in (0, 1)$

Крайний член вариационного ряда $-X_{(r)}, r$ — ограничено по n или X_{n+1-s}, s — ограничено

Теорема (об асимптотике среднего члена вариационного ряда)

Пусть $0 < \alpha < 1, p$ — теоретическая плотность, q_α — теоретическая квантиль порядка α

$p \in C^1(U(q_\alpha))$

Тогда $\sqrt{n}p(q_\alpha) \frac{X_{(\lfloor n\alpha \rfloor)} - q_\alpha}{\sqrt{\alpha(1-\alpha)}} \xrightarrow{d} N(0, 1)$

Доказательство

Комментарии к доказательству в лекции 3, 0:55

1. $k := \lfloor n\alpha \rfloor$. Выпишем плотность $X_{(k)}$

2. Напишем плотность преобразования над $X_{(k)}$

Теорема (об асимптотике крайнего члена вариационного ряда)

Пусть r, s — фиксированные, p — плотность

Тогда $nF(X_{(r)}) \xrightarrow{d} \Gamma(r, 1), nF(X_{(n+1-s)}) \xrightarrow{d} \Gamma(s, 1)$ — независимые

5 Точечное оценивание параметров

5.1 Постановка задачи точечного оценивания параметра

Пусть $X_1, \dots, X_n \sim F_\theta, \theta \in \textcircled{\mathbb{H}} \subset \mathbb{R}^d$ — параметр

В классической постановке θ — фиксированный неизвестный вектор

Цель: оценить θ в виде функции $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ от выборки

Замечание

1. Функции от выборки принято называть статистиками

2. Байесовская постановка: θ – случайная величина из известного априорного распределения

Определение (Состоятельность)

$\hat{\theta}$ – состоятельная оценка $\theta \Leftrightarrow \hat{\theta} \xrightarrow{P} \theta \Leftrightarrow P(\|\hat{\theta} - \theta\| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$

Определение (несмещенность)

$bias(\hat{\theta}) = E\hat{\theta} - \theta$ – смещение

$bias(\hat{\theta}) = 0 \Leftrightarrow \hat{\theta} \forall n$ – несмещенная

$bias(\hat{\theta}) = 0 \Leftrightarrow \hat{\theta}$ при $n \rightarrow \infty$ – асимптотическая несмещенная

Определение (асимптотическая нормальность)

$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{n} N(0, \Sigma_\theta)$

Определение (эффективность/оптимальность)

$\hat{\theta}_1$ – эффективнее $\hat{\theta}_2 \Leftrightarrow MSE(\hat{\theta}_1) < MSE(\hat{\theta}_2)$, где $MSE(\hat{\theta}) = E\|\hat{\theta} - \theta\|^2 = E(\hat{\theta} - \theta)^T(\hat{\theta} - \theta)$

$MSE(\hat{\theta}) = \text{tr}(\text{Var } \hat{\theta}) + \|bias(\hat{\theta})\|^2$

Доказательство

$E(\hat{\theta} - \theta)^T(\hat{\theta} - \theta) = E(\hat{\theta} - E\hat{\theta} + E\hat{\theta} - \theta)^T(\hat{\theta} - E\hat{\theta} + E\hat{\theta} - \theta) = E \underbrace{(\hat{\theta} - E\hat{\theta})^T(\hat{\theta} - E\hat{\theta})}_{\text{Var } \hat{\theta}} + \|bias(\hat{\theta})\|^2$

Метод моментов

Рассмотрим $g_1, \dots, g_d : \exists E g_i(X_1) = m_j(\theta_1, \dots, \theta_d) \xrightarrow{\text{выборочные аналоги}} \overline{g_i(X_1)} =$

$m_i(\hat{\theta}_1, \dots, \hat{\theta}_d)$ – получили уравнения от θ

Решая уравнения, получаем оценки

Часто берут $g_i(x) = x^i$ – отсюда метод моментов (но можно брать и другие функции)

1. Асимптотическая нормальность \Rightarrow состоятельность

Доказательство

$$\hat{\theta} - \theta = \frac{1}{\sqrt{n}} \sqrt{n}(\hat{\theta} - \theta) \xrightarrow{P} 0$$

2. Асимптотическая нормальность $\Rightarrow bias(\hat{\theta}) \rightarrow 0$

Доказательство

Пусть $d = 2$

$$P(|\theta - \hat{\theta}| > \varepsilon) = P\left(\frac{\sqrt{n}|\theta - E\hat{\theta}|}{\sigma} > \frac{\sqrt{n}\varepsilon}{\sigma}\right) = 1 - P\left(\frac{\sqrt{n}|\theta - E\hat{\theta}|}{\sigma} < \frac{\sqrt{n}\varepsilon}{\sigma}\right) \approx 2(1 - \Phi(\frac{\sqrt{n}\varepsilon}{\sigma})) = 2(1 - \Phi(\frac{\sqrt{n}\varepsilon}{\sigma})) \rightarrow 0$$

3. Состоятельность $\Rightarrow bias(\hat{\theta}) \rightarrow 0$

Доказательство

Следует из УЗБЧ

$$\overline{X} \xrightarrow{a.s.} \mu \Rightarrow E\overline{X} \rightarrow \mu$$

4. Пусть $d = 1, bias\hat{\theta} \rightarrow 0, Var\tilde{\theta} \rightarrow 0 \Rightarrow \hat{\theta}$ – состоятельная

Замечание

1. Если $(\overline{g_1(X)}, \dots, \overline{g_d(X)})$ – состоятельная оценка для $(\dots, \overline{Eg_i(X)}m_i, \dots)$, $\alpha_1, \dots, \alpha_d$ – непрерывные от $\overline{g_1(X)}, \dots, \overline{g_d(X)}$, то они состоятельные
2. Если $(\overline{g_1(X)}, \dots, \overline{g_d(X)})$ – асимптотически нормальные и g_1, \dots, g_d – гладкие, то каждая оценка асимптотически нормальная

6 Метод максимального правдоподобия

$$pmf : p(x, \theta) = p(x|\theta)$$

$$pdf : p(x, \theta) = p(x|\theta)$$

Все это будем называть плотностью

$$X_1, \dots, X_n \sim p(X|\theta)$$

$$L(X|\theta) = \prod_i p(X_i|\theta) \text{ – функция правдоподобия}$$

$$\hat{\theta}_* = \operatorname{argmax} L(X|\theta_i)$$

Предположим, что $\theta \in B$ – откp., $\theta_1 \neq \theta_2 \Rightarrow L(X, \theta_1) \neq L(X, \theta_2)$ Алгоритм

1. Рассмотрим $\ln L(X, \theta)$
2. Приравняем производную к нулю
3. Найдем максимум

Пример

$$Poly(1, p), p = (p_1, \dots, p_m)$$

ν_1, \dots, ν_m – количество наблюдений типа $1, \dots, m$

$$L(X, p) = p_1^{\nu_1} \cdot \dots \cdot p_m^{\nu_m}$$

$$\ln L(X, p) = \sum_{j=1}^{m-1} \nu_j \ln p_j + \nu_m \ln(1 - p_1 - \dots - p_{m-1})$$

$$\frac{\partial \ln L}{\partial \ln p_j} = \frac{\nu_j}{p_j} - \frac{\nu_m}{1 - p_1 - \dots - p_{m-1}}$$

Суммируем уравнения: $\nu_j(1 - \hat{p}_1 - \dots - \hat{p}_{n-1}) = \hat{p}_j \nu_m$

$$\hat{p}_m(n - \nu_m) = \nu_m(1 - \hat{p}_m)$$

$$\hat{p}_m = \frac{\nu_m}{n}$$

$$\text{Аналогично } \hat{p}_j = \frac{\nu_j}{n}$$

Определение (информация Фишера)

Для $d = 1$

$$L(X, \theta) = \prod p(X_j, \theta)$$

$$\ln L(X, \theta) = \sum \ln p(X_j, \theta)$$

$$V(X, \theta) = \frac{\partial \ln L}{\partial \theta} = \sum \frac{\partial \ln p}{\partial \theta} - \text{вклад выборки}$$

Пусть $\theta \in \textcircled{\mathbb{H}}$ – открыто

$$\theta_1 \neq \theta_2 \Rightarrow p(X, \theta_1) \neq p(X, \theta_2)$$

Регулярность:

$$1. \frac{\partial}{\partial \theta} \int_X T(X) L(X, \theta) \int_X \frac{\partial}{\partial \theta} L(X, \theta) T(X) \mathrm{d} x$$

Необходимое условие

$\text{supp } P_x$ нне зависит от θ

$$U[0, \theta] : \int_0^\theta \frac{1}{\theta} \mathrm{d} t = 1$$

$$\left(\int_0^\theta \frac{1}{\theta} \mathrm{d} t \right)' = \left(\frac{1}{\theta} \int_0^\theta \mathrm{d} t \right)' = -\frac{1}{\theta^2} \int_0^\theta \mathrm{d} t + \frac{1}{\theta} \neq \int_0^\theta \left(\frac{1}{\theta} \right)' \mathrm{d} t$$

$$2. EV^2(X, \theta) < \infty$$

$$\int_X L(X, \theta) \mathrm{d} X = 1$$

$$\int_X \frac{\partial L}{\partial \theta} \mathrm{d} X = \int_X \frac{\frac{L}{\theta}}{L} L \mathrm{d} X = \int_X V(X, \theta) L(X, \theta) \mathrm{d} X = EV(X, \theta) = 0$$

$I(\theta) = \text{Var} V(X, \theta) = EV^2(X, \theta)$ – информация Фишера всей выборки

$$V(X, \theta) = \sum_j \frac{\partial \ln \hat{p}(X_j, \theta)}{\partial \theta} = \text{Var } V(X, \theta) = n \underbrace{\text{Var } \frac{\partial \ln p(X_j, \theta)}{\partial \theta}}_{i(\theta) - \text{информация Фишера набора}}$$

$$\begin{aligned}
i(\theta) &= E\left(\frac{\partial \ln p(X_j, \theta)}{\partial \theta}\right)^2 = -E \frac{\partial^2 \ln p}{\partial \theta^2} \\
\frac{\partial}{\partial \theta} \int_{\mathbb{R}} \frac{\partial \ln p(x, \theta)}{\partial \theta} p(x, \theta) dx &= \int_{\mathbb{R}} \frac{\partial^2 \ln p(x, \theta)}{\partial \theta^2} p(x, \theta) dx + \int_{\mathbb{R}} \frac{\partial L}{\partial \theta} \frac{\partial p}{\partial \theta} dx = E \frac{\partial^2 \ln p}{\partial \theta^2} + \\
\underbrace{E\left(\frac{\partial \ln p}{\partial \theta}\right)^2}_{i(\theta)} &= 0
\end{aligned}$$

Для произвольного d

$$\begin{aligned}
i(\theta) &= -\left(E \frac{\partial^2 \ln p(X_1, \theta)}{\partial \theta_i \partial \theta_j}\right)_{1 \leq i, j \leq d} - \text{информационная матрица для 1 набора} \\
I(\theta) &= n \cdot i(\theta)
\end{aligned}$$

Рассмотрим $N(\theta_1, \theta_2)$

$$\begin{aligned}
p(x, \theta_1, \theta_2) &= \frac{1}{\sqrt{2\pi\theta_2}} \exp\left(-\frac{(x - \theta_1)^2}{2\theta_2}\right) \\
\ln p(x, \theta_1, \theta_2) &= -\frac{1}{2} \ln 2\pi - \frac{1}{2} \ln \theta_2 - \frac{(x - \theta_1)^2}{2\theta_2} \\
\frac{\partial \ln p}{\partial \theta_1} &= \frac{(x - \theta_1)}{\theta_2} \\
\frac{\partial \ln p}{\partial \theta_2} &= -\frac{1}{2\theta_2} + \frac{(x - \theta_1)^2}{2\theta_2^2} \\
\frac{\partial^2 f}{\partial \theta_1^2} &= -\frac{1}{\theta_2} \\
\frac{\partial^2 f}{\partial \theta_2^2} &= \frac{1}{2\theta_2^2} - \frac{(x - \theta_1)^2}{\theta_2^3} \\
\frac{\partial^2 f}{\partial \theta_1 \partial \theta_2} &= -\frac{(x - \theta_1)}{\theta_2^2} \\
i(\theta) &= \begin{pmatrix} \frac{1}{\theta_2} & 0 \\ 0 & \frac{1}{2\theta_2^2} \end{pmatrix}
\end{aligned}$$

По неравенству Рао-Крамера $\text{Var } \hat{\theta}_1 \geq \frac{\theta_2}{n}$

Теорема (неравенство Рао-Крамера)

Пусть модель регулярна, $d = 1$

$\tau(\theta)$ – оцениваемая функция, $\tau \in C^1$, $\tau(\theta) \equiv \theta$

$\hat{\tau}(\theta)$ – оценка несмещенная, т.е. $E(\hat{\tau}(\theta)) = \tau(\theta)$

Тогда $\text{Var } \hat{\tau}(\theta) \geq \frac{(\tau'(\theta))^2}{n \cdot i(\theta)}$

Доказательство

$$\tau'(\theta) = \int \hat{\tau}(\theta) \frac{\partial L}{\partial \theta} dx = \frac{\int \tau(\theta) V(X, \theta) L(X, \theta) dx}{E \hat{\tau}(\theta) V(x, \theta)} - EV(X, \theta) E \hat{\tau}(\theta) = \text{Cov}(V(X, \theta), \hat{\tau}(\theta))$$

$$\text{Cov}^2(V(X, \theta), \hat{\tau}(\theta)) \leq \text{Var } V(X, \theta) \text{Var } \hat{\tau}(\theta)$$

Замечание

1. $E \hat{\tau}(\theta) - \tau(\theta) = \text{bias}(\theta) \neq 0$
 $E \hat{\tau}(\theta) = \tau(\theta) + \text{bias}(\theta)$
 $\text{Var } \hat{\tau}(\theta) \geq \frac{(\tau'(\theta) + \text{bias}'(\theta))^2}{ni(\theta)}$
 $MSE(\tau(\theta)) \geq \frac{(\tau'(\theta) + \text{bias}'(\theta))^2}{ni(\theta)} + \text{bias}^2(\theta)$
2. $\text{Cov}^2(V(X, \theta), \hat{\tau}(\theta)) = \text{Var } V(X, \theta) \text{Var } \hat{\tau}(\theta)$, если $\hat{\tau}(\theta) = \alpha(\theta)V(X, \theta) + \tau(\theta)$

Теорема (неравенство Рао-Крамера)

Пусть модель регулярна, $d > 1$

$\tau(\theta) : \mathbb{R}^d \rightarrow \mathbb{R}, \tau \in C^1, \tau(\theta) \equiv \theta$

$\hat{\tau}(\theta)$ – оценка несмещенная, т.е. $E(\hat{\tau}(\theta)) = \tau(\theta)$

Тогда $\text{Var } \hat{\tau}(\theta) \geq \frac{\nabla \tau(\theta) i^{-1}(\theta) \nabla^T \tau(\theta)}{n}$

Свойства оценки максимального правдоподобия Если существует несмещенная оптимальная оценка в регулярном случае, то она совпадает с оценкой максимального правдоподобия

6.1 Состоятельность оценки максимального правдоподобия

Пусть θ_0 – реальный параметр, $\theta \neq \theta_0$

Тогда $P_{\theta_0}(L(X, \theta_0) > L(X, \theta)) \rightarrow 1$

Доказательство

$$\frac{L(X, \theta)}{L(X, \theta_0)} < 1$$

$$\frac{1}{n} \sum \ln \frac{p(X_j, \theta)}{p(X_j, \theta_0)} < 0$$

$$\text{По ЗБЧ } E_{\theta_0} \ln \frac{p(X_j, \theta)}{p(X_j, \theta_0)} \leq E_{\theta_0} \left(\frac{p(X_j, \theta)}{p(X_j, \theta_0)} - 1 \right) = \int_X p(X, \theta) dX - \int p(X, \theta_0) dX =$$

0

Пусть $S_n = \{X : \ln L(X, \theta_0) > \ln L(X, \theta_0 - \alpha)\} \cap \{X : \ln L(X, \theta_0) > \ln L(X, \theta_0 + \alpha)\}$

$$P_{\theta_0}(S_n) \rightarrow 1$$

$$A_n = \{X : |\hat{\theta} - \theta_0| < \alpha\}$$

$$B_n = \left\{X : \frac{\partial \ln L(X, \theta)}{\partial \theta} \bigg|_{\theta=\hat{\theta}} = 0\right\}$$

$$S_n \subset A_n B_n \subset A_n$$

Отсюда $P(A_n) \rightarrow 1$ – т.о. оценка состоятельная

6.2 Принцип инвариантности правдоподия

$$\theta \in \mathbb{H} \xleftrightarrow[\phi]{\text{биекция}} \gamma \in \Gamma$$

$$\gamma = \Phi(\theta)$$

$$\theta = \phi^{-1}$$

$$\sup_{\theta} L(X, \phi(\theta)) = \sup_{\gamma} L(X, \theta)$$

Пример

Дано $Exp(\lambda)$

$$\text{Тогда } \lambda e^{-\lambda x} \mapsto \frac{1}{\bar{X}}$$

$$\frac{1}{\bar{\lambda}} e^{-\frac{x}{\bar{\lambda}}} \mapsto \bar{X}$$

Теорема (асимптотическая нормальность оценки максимально-го правдоподобия)

Пусть модель регулярна

$$\left| \frac{\partial^3 \ln F(X, \theta)}{\partial \theta_i \partial \theta_j \partial \theta_k} \right| \leq M(X), EM(X) < \infty$$

θ_* – оценка максимального правдоподия

$\nabla \ln F(X, \theta) = 0$ – имеет единственное решение

Тогда

$$1. \sqrt{n}(\theta_* - \theta) \rightarrow N(0, i^{-1}(\theta))$$

2. Если $\tau(\theta)$ – оцениваемая и $\in C^1$, то

$$\sqrt{n}(\tau(\theta_*) - \tau(\theta)) \rightarrow N(0, \theta^2)$$

$$\sigma^2 = \nabla \tau(\theta) i^{-1}(\theta) \nabla \tau(\theta)$$

3. Если σ^2 непрерывная от σ , то $\sqrt{n} \frac{\tau(\sigma_*) - \tau(\theta)}{\sigma(\theta_*)} \rightarrow N(0, 1)$

Доказательство 1

$$V(X, \theta) = \frac{\partial \ln L(X, \theta)}{\partial \theta}$$

θ_0 – реальный параметр

$$V(X, \theta) = V(X, \theta_0) + V'_\theta(X, \theta_0)(\theta - \theta_0) + V''_\theta(X, \tilde{\theta}) \frac{(\theta - \theta_0)^2}{2}, \tilde{\theta} \in (\theta, \theta_0)$$

Выполним подстановку $\theta = \theta_*$

$$0 = V(X, \theta_0) + V'_\theta(X, \theta_0)(\theta_* - \theta_0) + V''_\theta(X, \tilde{\theta}) \frac{(\theta_* - \theta_0)^2}{2}$$

$$V'_\theta(X, \theta_0)(\theta_* - \theta_0) = -V(X, \theta_0) - V''_\theta(X, \tilde{\theta}) \frac{(\theta_* - \theta_0)^2}{2}$$

$$\sqrt{n} V'_\theta(X, \theta_0)(\theta_* - \theta_0) = -\sqrt{n} V(X, \theta_0) - \sqrt{n} V''_\theta(X, \tilde{\theta}) \frac{(\theta_* - \theta_0)^2}{2}$$

Заметим, что $V(X, \theta_0)$ на самом деле представляет сумму независимых одинаково распределенных величин с матожиданием 0 и дисперсией, равной информации Фишера

Тогда по ЦПТ $-\sqrt{n} V(X, \theta_0) = A_n = N(0, i(\theta))$

$$\sqrt{n} V''_\theta(X, \tilde{\theta}) \frac{(\theta_* - \theta_0)^2}{2} = n^{\frac{3}{2}} \underbrace{\frac{V''_\theta(X, \tilde{\theta})}{n}}_{\text{ограниченно по ЗБЧ}} \frac{(\theta_* - \theta_0)^2}{2}$$

ограниченно по ЗБЧ

$$V'_\theta(X, \theta_0) = n \frac{V'_\theta(X, \theta_0)}{n} \rightarrow -ni(\theta) \text{ по ЗБЧ}$$

$$\sqrt{n} V'_\theta(X, \theta_0)(\theta_* - \theta_0) \rightarrow N(0, i(\theta))$$

TO BE CONTINUED

Какая-то лажа, смотри <https://t.me/c/2069367863/1/726>

Определение

Вспомним неравенство Рао-Крамера

Показатель эффективности $-\frac{(\tau'(\theta))^2}{n \cdot i(\theta) \text{Var } \hat{\tau}(\theta)} \in [0, 1]$ для регулярных моделей

Если ПЭ = 1, то оценка эффективная

Определение

Пусть $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, \underbrace{\frac{\sigma^2}{n}}_{\text{какое-то число}})$

Показатель асимптотической эффективности $-\frac{1}{i(\theta)\sigma^2}$

6.3 Экспоненциальное семейство распределений

Пусть модель регулярна

Если $p(x, \theta) = \exp(A(\theta)B(x) + C(\theta) + D(x))$, то распределение относится к регулярному распределению

Примеры: $N, \Gamma, Pois, Bin, NB$

Свойства

$$\ln p(x, \theta) = A(\theta)B(x) + C(\theta) + D(x)$$

$$\frac{\partial \ln p(x, \theta)}{\partial \theta} = A'(\theta)B(x) + C'(\theta)$$

$$V(X, \theta) = A'(\theta) \sum B(X_i) + nC'(\theta)$$

$$V(X, \theta) = n(A'(\theta)\overline{B(X)} + C'(\theta))$$

$$\frac{V(X, \theta)}{n} - C'(\theta) = A'(\theta)\overline{B(X)}$$

$$\overline{B(X)} = \frac{V(X, \theta)}{nA'(\theta)} - \frac{C'(\theta)}{A'(\theta)}$$

Тогда $\overline{B(X)}$ – оптимальная оценка для $-\frac{C'(\theta)}{A'(\theta)}$ по критерию оптимальности

6.4 Байесовская постановка

$$X_1, \dots, X_n \in F_\theta$$

θ – неизвестный параметр

$\theta \sim \Pi(\theta)$ – априорное распределение

$l(\hat{\theta}, \theta)$ – функция потерь

$R(\hat{\theta}, \theta) = E_{F_\theta} l(\hat{\theta}, \theta)$ – риск

$r(\hat{\theta}) = E_{\pi(\theta)} R(\hat{\theta}, \theta)$ – байесовский риск

$\hat{\theta}_B = \operatorname{argmin}_{\hat{\theta}} r(\hat{\theta})$

$r(\hat{\theta}) = E_{(\pi(\theta), F_\theta)} l(\hat{\theta}, \theta)$

Теорема Байеса для плотностей

$$p(\theta|X) = \frac{L(X|\theta)\pi(\theta)}{\int L(X|\theta)\pi(\theta) d\theta}$$

Утверждение

$$\hat{\theta}_B = \operatorname{argmin}_{\hat{\theta}} E[l(\hat{\theta}, \theta)|X]$$

Доказательство

Пусть $\theta_* = \operatorname{argmin} \dots$

$$r(\theta_*) = EE[l(\theta_*, \theta)|X] \leq EE[l(\hat{\theta}, \theta)|X] = r(\hat{\theta})$$

Замечание

$$l(\hat{\theta}, \theta) = (\theta - \hat{\theta})^2 \Rightarrow \hat{\theta}_B = E[\theta|X]$$

6.5 Минимаксная оценка

$$m(\hat{\theta}) = \sup_{\theta} R(\hat{\theta}, \theta)$$

$$\hat{\theta}_{wc} = \operatorname{argmin} m(\hat{\theta}) - \text{минимаксная оценка}$$

Утверждение

$$r(\hat{\theta}) \leq \mu(\hat{\theta}) - \text{по определению}$$

Утверждение

Если $\exists \pi(\theta)$ – априорное распределение : $R(\hat{\theta}_B, \theta) \equiv \text{const}$

Тогда $\hat{\theta}_{wc} = \hat{\theta}_B$

Доказательство

Пусть $\exists \hat{\theta} : m(\hat{\theta}) < m(\theta)$

Тогда $r(\hat{\theta}) \leq m(\hat{\theta}) < m(\hat{\theta}_B) = r(\hat{\theta}_B)$ – противоречие с определением $\hat{\theta}_B$

6.6 Интервальное оценивание

Определение (доверительный интервал)

$$X_1, \dots, X_n \sim F_{\theta}, \theta \in \hat{\mathbb{H}} \subset \mathbb{R}$$

$1 - \alpha = \gamma \in (0, 1)$ – уровень доверия

Рассмотрим $(T_l(X), T_r(X))$ – доверительный интервал уровня $\gamma = 1 - \alpha$,
если $P(\theta \in (T_l(X), T_r(X))) \geq \gamma$

Классическая схема построения доверительных интервалов

Пусть $T(X, \theta) \sim G$ – не зависит от θ

Рассмотрим $P(q_1 < T(X, \theta) < q_2) = 1 - \alpha$ – доверительный интервал

$$\text{Потребуем, чтобы } P(T(X, \theta) \leq q_1) = P(T(X, \theta) \geq q_2) = \frac{\alpha}{2}$$

Тогда $q_1 = q_{\frac{\alpha}{2}}, q_2 = q_{1-\frac{\alpha}{2}}, q_{\bullet}$ – квантили

6.7 Доверительные интервалы параметров нормального закона

Лемма о независимости линейной и квадратической статистик

$X_1, \dots, X_n \sim N(\theta, \sigma^2) - i.i.d.$

$T = AX; X = (X_1, \dots, X_n)^T, A \in M_{m \times n}(\mathbb{R})$ – линейная статистика

$Q = X^T B X, B \in M_n(\mathbb{R}), B = B^T$ – квадратичная статистика

$AB = 0$

Тогда T, Q – независимые

Доказательство

$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m, 0, \dots, 0), \lambda_i \neq 0$ – потенциально нули в конце

$\Lambda - U^T B U$ – в силу симметричности

$U = (u_1, \dots, u_n)$ – собственные вектора, образуют ортонормированный базис

$$B = U \Lambda U^T = \sum_{j=1}^m \lambda_j u_j u_j^T$$

$$Q = \sum_{j=1}^m \lambda_j (X^T u_j)(u_j^T X) = \sum_j \lambda_j (u_j^T X)^2$$

$$A \left(\sum_{j=1}^m \lambda_j u_j u_j^T \right) = 0$$

$$\sum_{j=1}^m \lambda_j A u_j u_j^T = 0$$

Возьмем $k \in [1, m]$

Домножим справа на u_k

$$\sum_{j=1}^m \lambda_j A u_j \underbrace{u_j^T u_k}_{\mathbb{1}(j=k)} = 0$$

$$\lambda_k A u_k = 0$$

Отсюда $A u_k = 0$

Рассмотрим вектор $\begin{pmatrix} u^T \\ A \end{pmatrix} X$ – гауссовский вектор

Проверим, что $A_i X$ и $u_k^T X$ – независимые $\forall i, k$

$$\text{Cov}(A_i X, u_k^T X) = A_i \underbrace{\text{Cov}(X, X^T)}_{\neq 0} u_k = A_i \underbrace{\text{Var } X}_{\sigma^2 \cdot E} u_k = \sigma^2 A_i u_k = 0$$

Т.е. статистики независимые

Лемма о независимости двух независимых статистик

$$Q_1 = X^T B_1 X$$

$$Q_2 = X^T B_2 X$$

$$B_1 B_2 = B_2 B_1 = 0$$

Тогда Q_1, Q_2 – независимые

Доказательство

Аналогично

Определение

$$X_1, \dots, X_n \sim N(0, 1)$$

Тогда $\sum_{k=1}^n X_k^2 \sim \chi^2(n)$ – распределение хи-квадрат с n степенями свободы

Лемма о распределении квадратичной статистики

$$X_1, \dots, X_n \sim N(0, 1)$$

$$Q = X^T B X, B = B^2$$

$$r := \text{rg}(B)$$

Тогда $Q \sim \chi^2(r), r = \text{tr}(B)$

Доказательство

Заметим, что собственные числа либо 0, либо 1: $\lambda_{\underbrace{u}_{\text{с.в.}}} = Bu = B^2 u =$

$$B \lambda u = \lambda^2 u$$

$$B = \sum_{k=1}^n u_k u_k^T$$

$$Q = \sum_{k=1}^n (u_k^T X)^2$$

$$u_k^T X \sim N(\underbrace{u_k^T E X}_0, \underbrace{u_k^T E u_k}_1)$$

$$\text{Cov}(u_k^T X, u_j^T X) = 0$$

Тогда $Q \sim \chi(r)$

$$B = U \Lambda U^T$$

$$\text{rg } B = \text{rg } \Lambda = \text{tr } \Lambda$$

$$B_{jj} = \lambda_j u_j u_j^T = \lambda_j$$

Тогда $\text{tr } B = \text{tr } \Lambda = \text{rg } B$

Теорема Фишера

Пусть $X_1, \dots, X_n \sim N(\mu, \sigma^2)$

Тогда

$$1. \quad \bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

Доказательство очевидно

$$2. \frac{nS_*^2}{\sigma^2} = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

Доказательство

$$Y_j = \frac{X_j - \mu}{\sigma}$$

$$\bar{Y} = \frac{1}{\sigma}(\bar{X} - \mu)$$

$$S_*^2(Y) = \frac{1}{n} \sum_{j=1}^n (Y_j - \bar{Y})^2 = \frac{S_*^2(X)}{\sigma^2}$$

$$\bar{Y} = \frac{\sum Y_j}{n} = \underbrace{\left(\frac{1}{n} \quad \dots \quad \frac{1}{n} \right)}_b \begin{pmatrix} Y_1 \\ \vdots \\ Y_n \end{pmatrix} = bY$$

$$nS_*^2(Y) = (Y - bY)^T(Y - bY) = Y^T(E - B)^T(E - B)Y, B = \begin{pmatrix} b \\ \vdots \\ b \end{pmatrix}$$

$$(I - B)^T(I - B) = I - B$$

По предыдущей лемме $Y^T(E - B)^T(E - B)Y \sim \chi^2(\text{tr}(I - B))$

$$\text{tr}(I - B) = \sum_{k=1}^n \left(1 - \frac{1}{n}\right) = n - 1$$

$$3. S^2, \bar{X} - \text{независимые } S_*^2, \bar{X} - \text{независимые}$$

Доказательство

$$b(I - B) = b - b = 0$$

Тогда по лемме 1

Определение

$X_0, \dots, X_n - \text{i.i.d } N(0, 1)$

Тогда $\frac{X_0}{\sqrt{\frac{1}{n} \sum_{k=1}^n X_k^2}} \sim T(n)$ – распределение Стьюдента

Определение

$$\chi_n^2 \sim \chi^2(n)$$

$$\chi_m^2 \sim \chi^2(m) - \text{независимые}$$

$$\frac{\chi_n^2}{\chi_m^2} \sim F(n, m) - \text{распределение Фишера}$$

6.8 Асимптотические доверительные интервалы

$$\lim_{n \rightarrow \infty} P(\theta \in (l_n, r_n)) \geq 1 - \alpha$$

$$T(X, \theta) \xrightarrow[d]{} G, G \text{ не зависит от } \theta$$

7 Проверка статистических гипотез

Основное предположение (по умолчанию)

Альтернативное предположение (хотим доказать)

Определение

Пусть есть выборка в широком смысле X_1, \dots, X_n

Будем считать, что $(X_1, \dots, X_n) \sim F$

$H_0 := (F \in \mathcal{F}_0)$ – нулевая гипотеза (основная гипотеза)

$H_1 := (F \in \mathcal{F}_1)$ – альтернатива

$\alpha \in (0, 1)$ – уровень значимости

Проводим стат.тест/критерий $\delta(X, \alpha)$:

$$\delta(X, \alpha) = \begin{cases} \text{accept } H_0 & \text{данные не противоречат нулевой гипотезе} \\ \text{reject } H_0 \text{ with respect to } H_1 & \text{данные противоречат нулевой и свидетельствуют альтернативной} \end{cases}$$

Тест не подтверждает и не опровергает гипотезу, но позволяет делать некоторые выводы о гипотезе

Рассмотрим $T(X)$ – статистику критерия

$T(X) \sim G$ или $T(X) \xrightarrow[n \rightarrow \infty]{d} G$ при условии H_0

$P(T(X) \in T_0(\alpha) | H_0) = 1 - \alpha$

$P(T(X) \in T_1(\alpha) | H_0) = \alpha$ (при сходимости \approx)

Если $T(x) \in T_1(\alpha)$ – reject H_0

Иначе – accept H_0

$$\text{supp } G = \underbrace{T_0(\alpha)}_{\text{область принятия}} \sqcup \underbrace{T_1(\alpha)}_{\text{область опровержения}}$$

Виды тестов в зависимости от критической области:

1. Left-sided

$$T_0(\alpha) = [q_\alpha, +\infty), T_1(\alpha) = (-\infty, q_\alpha)$$

$$p_l = P(\Gamma \leq T(x) | H_0)$$

2. Right-sided

$$T_0(\alpha) = (-\infty, q_{1-\alpha}], T_1(\alpha) = (q_{1-\alpha}, +\infty) \quad p_r = P(\Gamma > T(x)|H_0)$$

3. Two-sided

$$T_0(\alpha) = [q_{\frac{\alpha}{2}}, q_{1-\frac{\alpha}{2}}], T_1 = \overline{T_0} \quad p = 2 \min(p_l, p_r)$$

Тогда мы получили еще одно условие:

Если $p < \alpha$ – reject H_0

Иначе ассепт H_0

p (p-value) – это максимальный уровень, при котором мы принимаем H_0

Виды ошибок:

1. first type error / false positive

$$P(T(X) \in T_1(\alpha)|H_0) = \alpha$$

2. second type error / false negative

$$P(T(X) \in T_0(\alpha)|H_1) = \beta$$

$1 - \beta$ – мощность критерия

Пример (spam classifier)

H_0 – не спам

H_1 – спам

Письма не фильтруются, $\alpha = 0 \Rightarrow \beta$ – большое, т.к. спама много

Все письма – спам, $\beta = 0 \Rightarrow \alpha$ – большое

7.1 Статистические критерии и доверительные интервалы

Вспомним задачу построения доверительного интервала

$$X_1, \dots, X_n \sim F_\theta, T(X, \theta) \rightarrow G, P(q_{\frac{\alpha}{2}} \leq T(X, \theta) \leq q_{1-\frac{\alpha}{2}}) = 1 - \alpha$$

Рассмотрим следующую стат. гипотезу

$$H_0 : \theta = \theta_0$$

$$P(T(X, \theta_0) \in T_\theta | \theta = \theta_0) = 1 - \alpha$$

$$H_1 : \theta \neq \theta_0 \text{ или } \theta > \theta_0 \text{ или } \theta < \theta_0$$

7.2 Критерий Колмагорова

$$X_1, \dots, X_n \sim F$$

$H_0 : F = F_0, F_0$ – непрерывная

$$H_1 : F \neq F_0$$

Теорема Колмагорова (напоминание)

$$P(\sqrt{n} \sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \leq t) \rightarrow K(t)$$

Статистика критерия: $D_n = \sqrt{n} \sup_{x \in \mathbb{R}} |F_n(x) - F(x)|, F_n$ – э.ф.р.

Если $D_n > q_{1-\alpha}$ – reject H_0

Иначе ассепт H_0

7.3 Критерий Смирнова

$X_1, \dots, X_n, Y_1, \dots, Y_m$ – независимые

$H_0 : F_X = F_Y (= F_0), F_0$ – непрерывная

$$H_1 : \neg H_0$$

$$D_{m,n} = \sqrt{\frac{nm}{n+m}} \sup_x |F_n(x) - F_m(x)|$$

$$T_1(\alpha) = (q_{1-\alpha}, +\infty)$$

7.4 Критерии типа хи-квадрат

Критерий согласия Пирсона

Пусть есть N -элементное множество

$p = (p_1, \dots, p_N)$ – настоящий вектор вероятностей (не знаем)

$p_0 = (p_{01}, \dots, p_{0N})$ – ожидаемый, фиксированный вектор вероятностей

ν_k – кол-во элементов типа k в выборке, $n = \sum_k \nu_k$

$$H_0 : p = p_0$$

$$H_1 : p \neq p_0$$

$$\text{Тогда возьмем статистику } \chi_N^2 = \sum_{k=1}^N \frac{(\nu_k - np_{0k})^2}{np_{0k}}$$

Теорема

$$\chi_N^2 \xrightarrow[n \rightarrow \infty]{} \chi^2(N-1) \text{ – при условии } H_0$$

Доказательство для $N = 2$

$$\frac{(\nu_1 - np_{01})^2}{np_{01}} + \frac{(\nu_2 - np_{02})^2}{np_{02}} = \frac{(\nu_1 - np_{01})^2}{n} \left(\frac{1}{p_{01} + \frac{1}{1-p_{01}}} \right) = \frac{(\nu_1 - np_{01})^2}{np_{01}(1-p_{01})} \rightarrow (N(0, 1))^2$$

Замечание

Критерий состоятельный (мощность стремится к 1)

Критическая область правосторонняя (если H_0 верна, то χ будет мало)

Усложним задачу

$$H_0 : p = p_0(\theta), \theta \in \circ H \subset \mathbb{R}^d, d < N - 1$$

$$\text{Тогда } \chi_N^2 = \sum_{k=1}^N \frac{(\nu_k - np_{0k}(\theta))^2}{np_{0k}(\theta)}$$

Вместо θ подставим оценку максимального правдоподобия

Теорема

$$p_0(\theta) > 0 \forall \theta$$

$$\frac{\partial p_0}{\partial \theta}, \frac{\partial}{\partial \theta} \frac{\partial}{\partial \theta} p_0 - \text{непрерывные}$$

$$\text{rg}\left(\frac{\partial p_{0k}}{\partial \theta_j}\right)_{1 \leq k \leq N, 1 \leq j \leq d} = d$$

$$\text{Тогда } \chi_N^2 \rightarrow \chi^2(N - 1 - \underbrace{d}_{\text{количество неизвестных}})$$

Критерий однородности

Есть K независимых выборок

Все они из $\{1 \dots, N\}$

Пусть $p^{(j)}$ – истинный вектор вероятностей для j -ой выборки

$H_0 : p^{(1)} = \dots = p^{(k)}$ – мы их не знаем

$H_1 : \neg H_0$

ν_{ij} – количество элементов j в выборке i

$$n_i = \sum \nu_{i*}$$

$$n = n_1 + \dots + n_k$$

Пусть $p^{(*)}$ известны

$$\chi_{n_1}^2 = \sum_j \frac{(\nu_{ij} - n_i p_j^{(i)})^2}{n_i p_j^{(i)}}, df = N - 1$$

$$\chi_n^2 = \sum \chi_{n_i}^2, df = k(N - 1)$$

Теперь $p^{(*)}$ – неизвестные. Тогда суммарно $(N - 1)$ неизвестных

Тогда из прошлой теоремы $df = k(N - 1) - (N - 1) = (N - 1)(k - 1)$

Подставим вместо $p^{(j)}$ оценку максимального правдоподобия $\hat{p}_j = \frac{\nu_{1j} + \dots + \nu_{kj}}{n}$

Критерий независимости

$$x_1, \dots, x_n \in \{1, \dots, N\}$$

$$y_1, \dots, y_n \in \{1, \dots, M\}$$

ν_{ij} – количество пар, в которых первая компонента i , вторая – j

$$p_{ij} = P(X = i, Y = j)$$

$$p_{X_i} = p(X = i)$$

$$p_{Y_j} = p(Y = j)$$

$$H_0 : p_{ij} = p_{X_i} p_{Y_j}$$

$$H_1 : \neg H_0$$

$$\chi^2 = \sum_{ij} \frac{(\nu_{ij} - p_{ij}n)^2}{np_{ij}}, df = NM - 1$$

Учитывая, что $p_{ij} = p_{X_i} p_{Y_j}$, $df = NM - 1 - N - M$